

Dicionário de Dados — Base: Perfil de Saúde e Estilo de Vida

Campo (Original)	Tipo Original	Descrição	Valores/Faixa Observada	Técnica Aplicada	Campo(s) Resultante(s)
PatientID	Numérico (inteiro)	Identificador único do paciente/registro	1 a 1000	Nenhuma (identificador, não é feature de ML)	PatientID
Age	Numérico (inteiro)	Idade do paciente em anos	18 a 79 anos	Normalização Min-Max (0 a 1)	Age
Gender	Texto (categórico binário)	Sexo do paciente	Male / Female	Encoding binário (Male=1, Female=0)	Gender
Height_cm	Numérico (decimal)	Altura do paciente em centímetros	143.9 a 192.5 cm	Normalização Min-Max (0 a 1)	Height_cm
Weight_kg	Numérico (decimal)	Peso do paciente em quilogramas	45.0 a 103.0 kg	Normalização Min-Max (0 a 1)	Weight_kg
Smoker	Texto (categórico binário)	Indica se o paciente é fumante	Yes / No	Encoding binário (Yes=1, No=0)	Smoker
ExerciseFrequency	Texto (categórico ordinal)	Frequência de exercício físico	Never / Sometimes / Often	Encoding ordinal (0,1,2) + Normalização Min-Max	ExerciseFrequency
Transportation	Texto (categórico nominal)	Meio de transporte mais utilizado	Walking / Bicycle / Automobile / Public Transport	One-Hot Encoding	Transport_Walking, Transport_Bicycle, Transport_Automobile, Transport_Public Transport
Region	Texto (categórico nominal)	Região onde o paciente reside	North / South / East / West	One-Hot Encoding	Region_North, Region_South, Region_East, Region_West
BloodPressure	Numérico (inteiro)	Pressão arterial sistólica (mmHg)	90 a 149 mmHg	Normalização Min-Max (0 a 1)	BloodPressure
Cholesterol	Numérico (inteiro)	Nível de colesterol total (mg/dL)	120 a 260 mg/dL	Normalização Min-Max (0 a 1)	Cholesterol
Income	Numérico (decimal)	Renda mensal do paciente (R\$)	R\$ 1227.58 a R\$ 43287.57	Normalização Min-Max (0 a 1)	Income
HasHealthInsurance	Texto (categórico binário)	Indica se o paciente possui plano de saúde	Yes / No	Encoding binário (Yes=1, No=0)	HasHealthInsurance
Diabetes	Texto (categórico binário)	Indica diagnóstico de diabetes (variável-alvo sugerida para Machine Learning)	Yes / No	Encoding binário (Yes=1, No=0)	Diabetes

Notas:

- Base sintética gerada para fins didáticos (1000 registros, 13 campos originais + ID).
- Encoding binário: categorias com apenas 2 valores viraram 0/1.
- Encoding ordinal: usado quando existe ordem natural entre as categorias (ExerciseFrequency).
- One-Hot Encoding: usado para categorias nominais sem ordem (Transportation, Region), evitando induzir uma hierarquia falsa entre elas.
- Normalização Min-Max: $x_{norm} = (x - min) / (max - min)$, aplicada às colunas numéricas contínuas/discretas para colocá-las na mesma escala (0 a 1).
- PatientID e a variável-alvo (Diabetes) não foram normalizados, pois um é apenas identificador e o outro já é binário.