

FACULDADE DE INFORMÁTICA E ADMINISTRAÇÃO PAULISTA – FIAP
TECNOLOGIA EM ANÁLISE E DESENVOLVIMENTO DE SISTEMAS

LEONARDO AFONÇO SOUSA
VITOR GONÇALVES DE SOUZA
SYANG CRISTINA GOMES SOUZA
JOÃO MACHADO NASCIMENTO
MATHEUS JONES SOUSA DE FREITAS

PERFIL DE SAÚDE E ESTILO DE VIDA:

análise visual dos fatores associados ao diagnóstico de diabetes

LEONARDO AFONÇO SOUSA
VITOR GONÇALVES DE SOUZA
SYANG CRISTINA GOMES SOUZA
JOÃO MACHADO NASCIMENTO
MATHEUS JONES SOUSA DE FREITAS

PERFIL DE SAÚDE E ESTILO DE VIDA:

análise visual dos fatores associados ao diagnóstico de diabetes

Trabalho apresentado à disciplina de AI & Chatbot do curso de Tecnologia em Análise e Desenvolvimento de Sistemas da Faculdade de Informática e Administração Paulista – FIAP, como requisito parcial para avaliação do Checkpoint 02.

Orientador: Prof. Alfonso Rodriguez.

SUMÁRIO

1 INTRODUÇÃO	3
2 BASE DE DADOS E METODOLOGIA	3
3 ANÁLISE DOS GRÁFICOS	4
3.1 Frequência de exercício físico e diabetes	4
3.2 Idade, tabagismo e diabetes	5
3.3 Índice de Massa Corporal e diabetes	6
3.4 Idade e pressão arterial	7
3.5 Correlação entre as variáveis	8
4 CONCLUSÃO	9
REFERÊNCIAS	10

1 INTRODUÇÃO

Este trabalho tem como objetivo utilizar a base de dados normalizada no Checkpoint 01 para responder, por meio de visualização de dados (*dataviz*), à seguinte pergunta central: quais características de saúde e de estilo de vida estão associadas ao diagnóstico de diabetes? Como o dicionário de dados indica a variável Diabetes como a variável-alvo sugerida para modelos de classificação, os gráficos foram construídos para comparar o grupo de pacientes com diabetes ao grupo sem a doença. Foram elaborados cinco gráficos de tipos diferentes (colunas, linhas, caixa, dispersão e mapa de calor), cada um acompanhado de um parágrafo que explica o que ele mostra.

2 BASE DE DADOS E METODOLOGIA


A base utilizada é sintética, gerada para fins didáticos, e possui 1.000 registros de pacientes, sem valores ausentes nem linhas duplicadas. Cada registro contém idade, sexo, altura, peso, hábito de fumar, frequência de exercício físico, meio de transporte, região, pressão arterial sistólica, colesterol total, renda mensal, posse de plano de saúde e diagnóstico de diabetes. No Checkpoint 01, as variáveis numéricas receberam normalização Min-Max (colunas com prefixo *N_*), as categóricas binárias foram convertidas em 0 e 1, a frequência de exercício recebeu codificação ordinal e as variáveis transporte e região passaram por *One-Hot Encoding*. Para que os gráficos fossem compreendidos visualmente, foram usados os valores originais das variáveis numéricas e os códigos foram traduzidos de volta para rótulos conforme o dicionário de dados (por exemplo, 1 = “Com diabetes” e 0 = “Sem diabetes”). Também foram derivados o Índice de Massa Corporal (IMC), calculado como peso dividido pelo quadrado da altura em metros, e seis faixas etárias. O processamento foi feito em Python com as bibliotecas *pandas* (MCKINNEY, 2010) e *Matplotlib* (HUNTER, 2007), utilizando cores distinguíveis por pessoas com daltonismo e formatos de marcador diferentes para cada grupo.

3 ANÁLISE DOS GRÁFICOS

3.1 Frequência de exercício físico e diabetes

A Figura 1 apresenta, em um gráfico de colunas, o percentual de pacientes com diabetes em cada nível de frequência de exercício físico. A taxa diminui à medida que a prática de atividade física aumenta: entre os pacientes que nunca se exercitam, 38,8% têm diabetes; entre os que se exercitam às vezes, a taxa cai para 22,0%; e entre os que se exercitam frequentemente, para 18,0%. Assim, o grupo sedentário apresenta uma taxa de diabetes mais de duas vezes maior que a do grupo mais ativo, o que indica a frequência de exercício como uma característica relevante para diferenciar os pacientes com e sem a doença.

Figura 1 – Taxa de diabetes por frequência de exercício físico




Fonte: Elaborado pelos autores (2026), com base na base de dados normalizada do Checkpoint 01.

3.2 Idade, tabagismo e diabetes

A Figura 2 utiliza um gráfico de linhas para mostrar como a taxa de diabetes evolui ao longo das faixas etárias, separando fumantes e não fumantes. Nos dois grupos a taxa cresce com a idade: entre os não fumantes, passa de 9,8% na faixa de 18 a 29 anos para 39,2% na faixa de 70 a 79 anos. A linha dos fumantes fica acima da linha dos não fumantes em todas as faixas e chega a 59,0% entre os fumantes de 70 a 79 anos; no total, 36,5% dos fumantes têm diabetes, contra 23,3% dos não fumantes. As oscilações da linha laranja se devem ao menor número de fumantes em cada faixa (entre 28 e 51 pessoas), mas a tendência indica que idade e tabagismo somam risco.

Figura 2 – Taxa de diabetes por faixa etária entre fumantes e não fumantes




Fonte: Elaborado pelos autores (2026), com base na base de dados normalizada do Checkpoint 01.

3.3 Índice de Massa Corporal e diabetes

A Figura 3 é um gráfico de caixa (*boxplot*), que resume a distribuição do IMC em cada grupo: a caixa reúne os 50% centrais dos pacientes, a linha branca marca a mediana, o losango marca a média, as hastes indicam a variação típica e os pontos cinza são valores atípicos. A caixa dos pacientes com diabetes está deslocada para cima: a mediana do IMC é 26,4 kg/m², contra 24,7 kg/m² no grupo sem diabetes, e os 50% centrais vão de 24,4 a 29,3 kg/m², contra 22,2 a 27,6 kg/m². A linha tracejada marca o IMC 25, a partir do qual a Organização Mundial da Saúde classifica o sobrepeso (WORLD HEALTH ORGANIZATION, 2000); 64,1% dos pacientes com diabetes estão acima desse limite, contra 47,6% dos pacientes sem a doença, o que mostra a associação entre excesso de peso e diabetes.

Figura 3 – Distribuição do IMC por diagnóstico de diabetes




Fonte: Elaborado pelos autores (2026), com base na base de dados normalizada do Checkpoint 01.

3.4 Idade e pressão arterial

A Figura 4 é um gráfico de dispersão em que cada ponto representa um paciente, posicionado pela idade (eixo horizontal) e pela pressão arterial sistólica (eixo vertical); os círculos azuis são pacientes sem diabetes e os triângulos laranja, pacientes com diabetes. A linha tracejada mostra a tendência geral: a pressão sobe, em média, de cerca de 110 mmHg aos 18 anos para cerca de 130 mmHg aos 79 anos, com correlação positiva moderada ($r = 0,54$). Os triângulos se concentram na parte direita e superior do gráfico, o que confirma que os pacientes com diabetes são, em média, mais velhos (55,1 anos contra 45,0) e têm pressão arterial mais alta (123,5 mmHg contra 118,2 mmHg).

Figura 4 – Idade e pressão arterial sistólica por diagnóstico de diabetes




Fonte: Elaborado pelos autores (2026), com base na base de dados normalizada do Checkpoint 01.

3.5 Correlação entre as variáveis

A Figura 5 é um mapa de calor com o coeficiente de correlação de Pearson entre as variáveis numéricas e binárias da base. Tons de vermelho indicam correlação positiva (as duas variáveis aumentam juntas), tons de azul indicam correlação negativa (uma aumenta enquanto a outra diminui) e o cinza claro indica ausência de relação; quanto mais forte a cor, mais forte a relação. Na última linha, que relaciona cada variável com o diagnóstico, as maiores associações positivas são com peso (0,27), idade (0,25), IMC e pressão (0,21), colesterol (0,19) e tabagismo (0,12), enquanto o exercício físico tem associação negativa (-0,18) e a renda praticamente não tem relação (0,04). Como nenhuma correlação isolada é forte, o diagnóstico depende da combinação de vários fatores, o que justifica o uso de um modelo de classificação com múltiplas variáveis.

Figura 5 – Correlação entre as variáveis de saúde e estilo de vida



Fonte: Elaborado pelos autores (2026), com base na base de dados normalizada do Checkpoint 01.

4 CONCLUSÃO

Os cinco gráficos mostram um perfil consistente: os pacientes com diabetes da base são, em média, mais velhos, mais pesados, mais sedentários, com pressão arterial e colesterol mais altos e com maior proporção de fumantes. Por outro lado, a renda não apresentou relação com o diagnóstico. Como cada fator, isoladamente, tem associação apenas fraca ou moderada com a doença, a visualização indica que um modelo de classificação deve considerar as variáveis em conjunto, priorizando idade, peso ou IMC, exercício físico, pressão arterial, colesterol e tabagismo. Por se tratar de uma base sintética, as conclusões têm valor didático e não devem ser generalizadas para a população real.

REFERÊNCIAS

ASSOCIAÇÃO BRASILEIRA DE NORMAS TÉCNICAS. **NBR 6023**: informação e documentação: referências: elaboração. Rio de Janeiro: ABNT, 2018.

ASSOCIAÇÃO BRASILEIRA DE NORMAS TÉCNICAS. **NBR 14724**: informação e documentação: trabalhos acadêmicos: apresentação. Rio de Janeiro: ABNT, 2011.

HUNTER, J. D. Matplotlib: a 2D graphics environment. **Computing in Science & Engineering**, v. 9, n. 3, p. 90-95, 2007.

MCKINNEY, W. Data structures for statistical computing in Python. *In*: PYTHON IN SCIENCE CONFERENCE, 9., 2010, Austin. **Proceedings** [...]. Austin: SciPy, 2010. p. 56-61.

WORLD HEALTH ORGANIZATION. **Obesity**: preventing and managing the global epidemic. Geneva: WHO, 2000. (WHO Technical Report Series, 894).