

FACULDADE DE INFORMÁTICA E ADMINISTRAÇÃO PAULISTA – FIAP
TECNOLOGIA EM ANÁLISE E DESENVOLVIMENTO DE SISTEMAS

LEONARDO AFONÇO SOUSA
VITOR GONÇALVES DE SOUZA
SYANG CRISTINA GOMES SOUZA
JOÃO MACHADO NASCIMENTO
MATHEUS JONES SOUSA DE FREITAS

PERFIL DE SAÚDE E ESTILO DE VIDA:

análise visual dos fatores associados ao diagnóstico de diabetes

LEONARDO AFONÇO SOUSA
VITOR GONÇALVES DE SOUZA
SYANG CRISTINA GOMES SOUZA
JOÃO MACHADO NASCIMENTO
MATHEUS JONES SOUSA DE FREITAS

PERFIL DE SAÚDE E ESTILO DE VIDA:

análise visual dos fatores associados ao diagnóstico de diabetes

Trabalho apresentado à disciplina de AI & Chatbot do curso de Tecnologia em Análise e Desenvolvimento de Sistemas da Faculdade de Informática e Administração Paulista – FIAP, como requisito parcial para avaliação do Checkpoint 02.

Orientador: Prof. Alfonso Rodriguez.

SUMÁRIO

1 INTRODUÇÃO	3
2 BASE DE DADOS E METODOLOGIA	3
3 ANÁLISE DOS GRÁFICOS	4
3.1 Exercício físico, tabagismo e diabetes	4
3.2 Idade, sexo e diabetes	5
3.3 Índice de Massa Corporal e diabetes	6
3.4 Idade e pressão arterial	7
3.5 Correlação entre as variáveis	8
4 CONCLUSÃO	9
REFERÊNCIAS	10

1 INTRODUÇÃO

Este trabalho tem como objetivo utilizar a base de dados normalizada no Checkpoint 01 para responder, por meio de visualização de dados (*dataviz*), à seguinte pergunta central: quais características de saúde e de estilo de vida estão associadas ao diagnóstico de diabetes? Como o dicionário de dados indica a variável Diabetes como a variável-alvo sugerida para modelos de classificação (diagnóstico presente em 26,2% dos 1.000 pacientes), os gráficos foram construídos para comparar o grupo de pacientes com diabetes ao grupo sem a doença. Foram elaborados cinco gráficos de tipos diferentes (colunas agrupadas, linhas, caixa, dispersão e mapa de calor), cada um acompanhado de um parágrafo que explica o que ele mostra.

2 BASE DE DADOS E METODOLOGIA


A base utilizada é sintética, gerada para fins didáticos, e possui 1.000 registros de pacientes, sem valores ausentes nem linhas duplicadas. Cada registro contém idade, sexo, altura, peso, hábito de fumar, frequência de exercício físico, meio de transporte, região, pressão arterial sistólica, colesterol total, renda mensal, posse de plano de saúde e diagnóstico de diabetes. No Checkpoint 01, as variáveis numéricas receberam normalização Min-Max (colunas com prefixo *N_*), as categóricas binárias foram convertidas em 0 e 1, a frequência de exercício recebeu codificação ordinal e as variáveis transporte e região passaram por *One-Hot Encoding*. Para que os gráficos fossem compreendidos visualmente, foram usados os valores originais das variáveis numéricas e os códigos foram traduzidos de volta para rótulos conforme o dicionário de dados (por exemplo, 1 = “Com diabetes” e 0 = “Sem diabetes”). Também foram derivados o Índice de Massa Corporal (IMC), calculado como peso dividido pelo quadrado da altura em metros, e seis faixas etárias. O processamento foi feito em Python com as bibliotecas *pandas* (MCKINNEY, 2010) e *Matplotlib* (HUNTER, 2007), utilizando cores distinguíveis por pessoas com daltonismo e formatos de marcador diferentes para cada grupo.

3 ANÁLISE DOS GRÁFICOS

3.1 Exercício físico, tabagismo e diabetes

A Figura 1 apresenta, em um gráfico de colunas agrupadas, o percentual de pacientes com diabetes em cada nível de frequência de exercício físico, separando não fumantes (azul) e fumantes (laranja); a taxa geral de cada nível aparece abaixo do eixo. A taxa geral diminui à medida que a prática de atividade física aumenta: 38,8% entre os que nunca se exercitam, 22,0% entre os que se exercitam às vezes e 18,0% entre os que se exercitam frequentemente. Em todos os níveis, os fumantes têm percentual maior que os não fumantes, e entre os mais ativos a taxa dos fumantes é quase o dobro (28,6% contra 14,8%). A combinação de sedentarismo e tabagismo concentra o maior risco observado (46,1%), mais de três vezes a taxa dos não fumantes que se exercitam com frequência, o que indica as duas variáveis como relevantes para diferenciar os pacientes com e sem a doença.

Figura 1 – Taxa de diabetes por frequência de exercício físico e tabagismo




Fonte: Elaborado pelos autores (2026), com base na base de dados normalizada do Checkpoint 01.

3.2 Idade, sexo e diabetes

A Figura 2 utiliza um gráfico de linhas para mostrar como a taxa de diabetes evolui ao longo das faixas etárias. A linha preta, que representa todos os pacientes, cresce de forma praticamente contínua, de 13,6% na faixa de 18 a 29 anos para 44,0% na faixa de 70 a 79 anos, o que evidencia a idade como fator associado ao diagnóstico ($r = 0,25$). As linhas tracejadas separam os sexos: no conjunto, os homens têm taxa maior (31,2%) que as mulheres (21,3%), e na faixa de 70 a 79 anos chegam a 49,4%, contra 37,1% das mulheres. As oscilações das linhas por sexo, como a queda entre as mulheres de 60 a 69 anos, decorrem do menor número de pacientes em cada faixa (entre 67 e 109 pessoas), mas a tendência de alta com a idade se mantém nos dois grupos.

Figura 2 – Taxa de diabetes por faixa etária, geral e por sexo




Fonte: Elaborado pelos autores (2026), com base na base de dados normalizada do Checkpoint 01.

3.3 Índice de Massa Corporal e diabetes

A Figura 3 é um gráfico de caixa (*boxplot*), que resume a distribuição do IMC em cada grupo: a caixa reúne os 50% centrais dos pacientes, a linha branca marca a mediana, o losango marca a média, as hastes indicam a variação típica e os pontos cinza são valores atípicos. A caixa dos pacientes com diabetes está deslocada para cima: a mediana do IMC é 26,4 kg/m², contra 24,7 kg/m² no grupo sem diabetes, e os 50% centrais vão de 24,4 a 29,3 kg/m², contra 22,2 a 27,6 kg/m². A linha tracejada marca o IMC 25, a partir do qual a Organização Mundial da Saúde classifica o sobrepeso (WORLD HEALTH ORGANIZATION, 2000); 64,1% dos pacientes com diabetes estão acima desse limite, contra 47,6% dos pacientes sem a doença. Ainda assim, as caixas se sobrepõem bastante, o que indica que o IMC contribui para o risco, mas não o determina isoladamente ($r = 0,21$).

Figura 3 – Distribuição do IMC por diagnóstico de diabetes




Fonte: Elaborado pelos autores (2026), com base na base de dados normalizada do Checkpoint 01.

3.4 Idade e pressão arterial

A Figura 4 é um gráfico de dispersão em que cada ponto representa um paciente, posicionado pela idade (eixo horizontal) e pela pressão arterial sistólica (eixo vertical); os círculos azuis são pacientes sem diabetes e os triângulos laranja, pacientes com diabetes. A linha tracejada mostra a tendência geral: a pressão sobe cerca de 3,3 mmHg a cada dez anos de vida, de aproximadamente 110 mmHg aos 18 anos para 130 mmHg aos 79 anos, com correlação positiva moderada ($r = 0,54$), a mais forte entre as variáveis da base. Os triângulos se concentram na parte direita e superior do gráfico, o que confirma que os pacientes com diabetes são, em média, mais velhos (55,1 anos contra 45,0) e têm pressão arterial mais alta (123,5 mmHg contra 118,2 mmHg).

Figura 4 – Idade e pressão arterial sistólica por diagnóstico de diabetes




Fonte: Elaborado pelos autores (2026), com base na base de dados normalizada do Checkpoint 01.

3.5 Correlação entre as variáveis

A Figura 5 é um mapa de calor com o coeficiente de correlação de Pearson entre as variáveis numéricas e binárias da base. Tons de vermelho indicam correlação positiva (as duas variáveis aumentam juntas), tons de azul indicam correlação negativa (uma aumenta enquanto a outra diminui) e o cinza claro indica ausência de relação; quanto mais forte a cor, mais forte a relação. Na última linha, que relaciona cada variável com o diagnóstico, as maiores associações positivas são com peso (0,27), idade (0,25), IMC e pressão (0,21), colesterol (0,19) e tabagismo (0,12), enquanto o exercício físico tem associação negativa (-0,18) e a renda praticamente não tem relação (0,04). Como nenhuma correlação isolada é forte, o diagnóstico depende da combinação de vários fatores, o que justifica o uso de um modelo de classificação com múltiplas variáveis.

Figura 5 – Correlação entre as variáveis de saúde e estilo de vida



Fonte: Elaborado pelos autores (2026), com base na base de dados normalizada do Checkpoint 01.

4 CONCLUSÃO

Os cinco gráficos mostram um perfil consistente: os pacientes com diabetes da base são, em média, mais velhos, mais pesados, mais sedentários, com pressão arterial e colesterol mais altos, e o diagnóstico é mais frequente entre fumantes e entre homens. Por outro lado, a renda não apresentou relação com o diagnóstico. Como cada fator, isoladamente, tem associação apenas fraca ou moderada com a doença, a visualização indica que um modelo de classificação deve considerar as variáveis em conjunto, priorizando idade, peso ou IMC, exercício físico, tabagismo, pressão arterial e colesterol; como próxima etapa, recomenda-se treinar esse modelo com as variáveis normalizadas no Checkpoint 01. Por se tratar de uma base sintética e de correlações, os resultados têm caráter exploratório e didático, não indicam relação de causa e efeito e não devem ser generalizados para a população real.

REFERÊNCIAS

ASSOCIAÇÃO BRASILEIRA DE NORMAS TÉCNICAS. **NBR 6023**: informação e documentação: referências: elaboração. Rio de Janeiro: ABNT, 2018.

ASSOCIAÇÃO BRASILEIRA DE NORMAS TÉCNICAS. **NBR 14724**: informação e documentação: trabalhos acadêmicos: apresentação. Rio de Janeiro: ABNT, 2011.

HUNTER, J. D. Matplotlib: a 2D graphics environment. **Computing in Science & Engineering**, v. 9, n. 3, p. 90-95, 2007.

BASE DE SAÚDE NORMALIZADA. **Dicionário de dados**: perfil de saúde e estilo de vida. Base sintética, 1.000 registros. São Paulo: FIAP, 2026.

MCKINNEY, W. Data structures for statistical computing in Python. *In*: PYTHON IN SCIENCE CONFERENCE, 9., 2010, Austin. **Proceedings** [...]. Austin: SciPy, 2010. p. 56-61.

RODRIGUEZ, A. **AI & Chatbot**: Checkpoint 02: gráficos e gerenciamento de dados, classificação com dataviz. São Paulo: FIAP, 2026. Material didático.

WORLD HEALTH ORGANIZATION. **Obesity**: preventing and managing the global epidemic. Geneva: WHO, 2000. (WHO Technical Report Series, 894).